

# 可視光虹彩認証の認証損失を用いた画像輝度補正

鈴木 浩太<sup>1,a)</sup> 戸泉 貴裕<sup>2</sup> 庄司 悠歩<sup>2</sup> 大塚 陸人<sup>2</sup> 市野 将嗣<sup>1</sup>

**概要：**虹彩認証では一般的には安定して鮮明な虹彩画像を取得できる近赤外カメラが用いられるが、近赤外画像の撮影には専用の装置が必要となる。虹彩認証の適用先を拡大するためには既に広く普及している可視光カメラを用いて認証できることが望ましいが、可視光虹彩認証では周囲の照明環境や虹彩の色といった要因による輝度変化のために認証性能が大きく劣化する場合がある。そこで本稿では、様々な照明環境下で認証性能を維持するために、教師なし深層学習による可視光虹彩画像の輝度補正手法を提案する。本手法では、虹彩認証の認証損失を輝度補正モデルの学習に組み込むことで、個人識別性を維持した高輝度画像を生成するよう学習を促す。学習した輝度補正モデルを前処理として低輝度可視光虹彩画像に適用することにより、被認証者の撮影環境に影響されない安定した可視光虹彩認証を実現する。評価実験の結果、提案手法を使用することで既存の輝度補正手法と比較して、低輝度化した可視光虹彩データセット UBIRIS.v2 に対する Equal Error Rate が 6.62% から 4.30% に改善することを示す。

**キーワード：**可視光虹彩認証, 深層学習, 教師なし学習, 低輝度画像, 輝度補正

## Image Brightness Correction using Recognition Loss in Visible Iris Recognition

KOTA SUZUKI<sup>1,a)</sup> TAKAHIRO TOIZUMI<sup>2</sup> YUHO SHOJI<sup>2</sup> RIKUTO OTSUKA<sup>2</sup> MASATSUGU ICHINO<sup>1</sup>

**Abstract:** Iris recognition generally uses NIR cameras, which can capture clear iris images, but specialized equipment is required to capture NIR images. To expand the application of iris recognition, it is desirable to use visible light cameras, which are already widely available, for recognition. However, visible light iris recognition can degrade in recognition performance due to changes in brightness caused by factors such as the lighting environment and iris color. Therefore, in this paper, we propose a brightness correction method for visible iris images using unsupervised deep learning to maintain recognition performance under various lighting conditions. In this method, we use the recognition loss of iris recognition in the learning of the model to assist learning to generate high-brightness images while maintaining identifiability. By applying the model as a preprocessing to low-brightness visible light iris images, we achieve stable visible iris recognition that is not affected by the subject's lighting environment. Evaluation experiments show that using the proposed method improves the Equal Error Rate for the low-brightness visible light iris dataset UBIRIS.v2 from 6.62% to 4.30% compared to existing brightness correction methods.

**Keywords:** Visible Iris Recognition, Deep Learning, Unsupervised Learning, Low Brightness, Brightness Correction

### 1. はじめに

虹彩認証は、人間の虹彩が持つ複雑な模様を利用するため、生体認証の中でも特に高い精度で個人を識別することが可能である [1]。既存の虹彩認証システムでは、虹彩模様を鮮明に取得するために近赤外カメラを用いて虹彩を撮影

<sup>1</sup> 電気通信大学大学院  
The University of Electro-Communications  
<sup>2</sup> 日本電気株式会社バイオメトリクス研究所  
NEC Corporation  
<sup>a)</sup> ko.suzuki@uec.ac.jp

することが多いが、近赤外虹彩認証は精度が安定している反面、専用の機器が必要であるため適用先が限られるという問題がある。したがって、虹彩認証の適用先を拡大するためには、既に広く普及している可視光カメラで撮影された画像でも高精度な認証が可能であることが望ましい。

可視光領域では近赤外領域と比較して自然光の影響が強く現れるため、可視光虹彩画像は屋内であっても撮影環境によって輝度が大きく変化しやすい。また、可視光領域では虹彩の色によって光の反射率が異なるため、被認証者の虹彩の色が暗い場合はテクスチャが隠れてしまい認証精度が低下する。よって、可視光虹彩認証には撮影条件による虹彩画像の輝度の不安定さが認証精度に影響するという問題がある。顔認証の分野では、低輝度の顔画像を明るく補正する前処理によって認証性能を向上させる試みが行われている [2], [3]。一方で、可視光虹彩認証では低輝度画像の輝度補正に注目する先行研究の事例は少ない。したがって、被認証者の撮影条件によらない安定した認証を可能にするために、可視光虹彩画像の輝度を補正する手法についての検討が必要である。

一般画像認識の分野においては、低輝度画像に対する輝度補正手法が数多く提案されている。近年では、深層学習モデルを輝度補正に利用する手法が複数提案されており [4], [5], [6], [7], [8], [9], [10], 非深層学習の手法と比較して高い品質の高輝度画像を得られることが示されている。初期に提案された深層学習を用いた輝度補正手法の多くは、モデルの学習に教師あり学習を採用していた [4], [5], [6], [7]。教師あり学習による手法は、実装や学習方法の設計が比較的単純である一方で、同じ場面の高輝度画像と低輝度画像がペアになったデータセットを用意しなければならないという難点があった。この問題に対処するために、低輝度画像と高輝度画像のペアデータセットを用意することなく学習を行う教師なし学習の補正手法が提案されている [8], [9], [10]。しかし、一般画像認識の分野で提案された手法は主に視覚的品質の改善を目的としたものであり、本研究が対象としている認証タスクに注目して設計されたものではない。

以上を踏まえて本稿では、教師なし深層学習に基づいた可視光虹彩画像の輝度補正手法を提案する。可視光虹彩認証において、低輝度の虹彩画像が入力された際に本手法を前処理として適用することで、虹彩の色の明るさに関わらず入力画像の虹彩の輝度を特徴抽出器と相性の良い輝度に補正し、安定した認証が可能になることが期待される。本稿の貢献は以下の通りである。

- 教師なし深層学習に基づいた可視光虹彩画像の輝度補正手法を提案する。モデルの学習時に虹彩認証の認証損失を使用することにより、個人識別性を維持した高輝度画像を得ることができる。我々が調査した限りでは、虹彩認証の分野において深層学習を用いた輝度補

正手法は提案されていない。

- 可視光虹彩認証の研究において広く用いられている UBIRIS.v2[11] を低輝度化したデータセットを用いた評価により、提案手法による輝度補正が低輝度の可視光虹彩認証において既存の補正手法よりも有効であることを定量的に示す。

## 2. 先行研究

### 2.1 一般画像認識における輝度補正

一般画像認識の分野における画像の視認性を向上させるための輝度補正手法として、画像の輝度値ヒストグラムを平坦化して画素値の分布を一様にすることでコントラストを改善するヒストグラム平坦化 (HE) がある。画像全体に一律な平坦化を行った場合、局所領域のコントラスト改善効果が弱い場合がある。そこで、画像を小領域に分割してそれぞれに HE を適用することで局所的な改善効果を向上させた CLAHE[12] という発展的手法が提案された。

ヒストグラム平坦化以外の方法として、人間の視覚に基づいて画像から照明成分の影響を除くことで鮮明な高輝度画像を得る Retinex 理論 [13] に基づいた手法がある。Jobson らは、注目画素と周辺の輝度比から反射率成分を導出する C/S 型 Single-Scale Retinex (SSR) [14] と、それを多重化した Multi-Scale Retinex (MSR) [15] を提案した。Fu ら [16] は、重み付き変分モデルを導入して照明成分の推定モデルを改善した SRIE を提案した。Guo ら [17] は、画像の構造を考慮した平滑化モデルを用いて照明成分を推定する LIME を提案した。

### 2.2 一般画像認識における深層学習を用いた輝度補正

近年では、画像の輝度補正に深層学習モデルを用いる研究が数多く行われている [4], [5], [6], [7], [8], [9], [10]。深層学習を用いて低輝度の訓練画像から輝度補正モデルを学習することにより、入力に応じた高品質な高輝度画像を生成できることが明らかになっている。

Tao ら [4] は、LLCNN と呼ばれる輝度補正用に設計された CNN モデルを提案し、従来の非深層学習の手法と比較して高品質な高輝度画像を生成できることを示した。Shen ら [5] は、残差接続を持つ CNN で MSR の処理プロセスを模倣した MSR-Net というモデルを提案した。Wei ら [6] は、Retinex に基づく画像の分解モデルと照明成分の輝度補正モデルを合わせて学習する RetinexNet を提案した。

深層学習を用いた手法の多くは、同じ場面の高輝度画像と低輝度画像のペアを用いて学習する教師あり学習を採用している。しかし、同時に撮影された低輝度・高輝度画像で構築された公開ペアデータセットは数が少ない。また Cai ら [7] は、人工的に生成した低輝度画像は通常の高輝度画像と比べて輝度分布が不自然に理想的であるため、教師画像としてモデルの訓練に使用すると生成画像にアーティ

ファクトが生じる可能性があることを指摘した。そこで Jiang ら [8] は、低輝度・高輝度画像のペアを必要としない教師なし学習の手法として、GAN を用いて低輝度画像空間と高輝度画像空間のマッピングを学習する EnlightenGAN を提案した。Jiang らは評価実験を通して、既存の教師あり学習や非深層学習の手法と比較して高品質な高輝度画像を生成できるほか、EnlightenGAN による輝度補正が低輝度の一般画像における分類タスクの精度向上にも有効であることを示した。また、事前知識を用いて設計した損失関数を用いることで、教師データを参照せずにモデルを学習するゼロショット学習を輝度補正タスクに取り入れる研究も複数みられている [9], [10]。

### 2.3 虹彩認証における輝度補正

さまざまな場面において虹彩認証を適用することを考えると、撮影環境によっては画像の全体または一部の輝度が極端に小さくなる場合がある。そのような低輝度虹彩画像は、虹彩模様が不鮮明になるため個人識別性が低下し、正確な認証が困難になる。したがって、虹彩認証の精度の低下を防ぐための前処理として輝度やコントラストの改善を行う検討がいくつかみられている。

Hassan ら [18] は、可視光虹彩認証における画像強調の有効性を示すために、通常の HE, AHE, CLAHE の 3 種類について比較を行った。比較評価の結果により、CLAHE を使用した場合が最も画像の品質が高く認証精度も改善されることを示した。Sajjad ら [19] は、鮮明でない虹彩画像に対する認証精度を改善するために、CLAHE とヒストグラムを拡張する処理を適用した。Alvarez-Betancourt ら [20] や Santos ら [21], Alwawi ら [22] も、提案する虹彩認証手法の前処理として CLAHE を採用しており、虹彩認証の前処理として CLAHE が広く使用されているといえる。

Kumar ら [23] は、HE, メディアンフィルタ, ガンマ補正, トップハット・ボトムハットフィルタリングで画像の輝度とコントラストを引き上げる手法を提案し、近赤外虹彩認証においてその有効性を示した。Das ら [24] は、ファジィ統計によって調整された輝度ヒストグラムを用いて滑らかな画像強調を行う BPDFHE[25] を前処理に採用し、モバイル端末で撮影された可視光虹彩画像に対する有効性を示した。Raffei ら [26] は CLAHE の改良版として、累積分布関数を改良したヒストグラム平坦化とエントロピーに基づく ClipLimit の選択を導入した iso-CLAHE という手法を提案し、虹彩画像の認識性を向上させ認証性能を向上させる効果があることを示した。

### 2.4 虹彩認証の輝度補正における課題

前節で述べた通り、虹彩認証の分野においても輝度やコントラストを改善することによって認証精度を向上させようとする試みはみられている。しかし、これらの試みは主

に虹彩画像の輝度を正規化することを目的としており、必ずしも高輝度化を目的としているわけではない場合が多い。また、虹彩認証において使用された手法は視覚的品質を向上させることを目的として設計されたものが多く、ほとんどは認証を想定したものではない。

さらに、2.3 節で挙げた手法はいずれも非深層学習の手法であり、虹彩認証の分野で深層学習を用いた輝度補正手法を提案・適用している研究は、我々が調査した限りでは確認できなかった。2.2 節で述べた通り、一般画像認識においては深層学習に基づく輝度補正手法の多くが非深層学習の手法を上回ることが示されている。したがって、虹彩画像で学習した深層学習ベースの輝度補正手法を使用することで、認証精度をさらに向上させることができると考えられる。

## 3. 提案手法

2.4 節で述べた課題点を踏まえて、本稿では教師なし学習による深層学習に基づいた可視光虹彩画像の輝度補正手法を提案する。提案手法のポイントは次の通りである。

- 一般画像認識の分野で提案された教師なし学習の輝度補正モデルである EnlightenGAN[8] をベースとすることで、可視光虹彩認証における教師なし学習の輝度補正モデルの作成を実現する。これにより、認証環境下での虹彩画像の高輝度・低輝度画像ペアデータセットを必要とせずにモデルを学習できる。
- 虹彩認証の認証損失を輝度補正モデルの学習時に使用する。これにより、個人識別性が高く認証に適した画像をモデルが生成できるようになる。

提案手法における学習方法の概要図を図 1 に示す。以下では、提案手法におけるモデルの構成と学習方法の概要を説明する。

### 3.1 アーキテクチャ

2.2 節で述べたように、一般画像認識における深層学習を用いた輝度補正手法の多くで採用されている教師あり学習では、入力の高輝度画像と、解答となる同一の場面の高輝度画像のペアを用意する必要がある。しかし、可視光虹彩認証での適用を考えると、同時に撮影された異なる輝度の虹彩画像を含む大規模なデータセットは現時点では公開されていないという問題がある。また、人工的に合成された低輝度画像を教師画像として用いる方法は、生成画像にアーティファクトが生じる原因になることが指摘されている [7]。以上を踏まえて、深層学習に基づく輝度補正を可視光虹彩認証の前処理として利用できるようにするためには、ペアデータセットを必要とすることなくモデルを学習できることが望ましい。ペアデータセットを使用しないモデルの学習方法として教師なし学習とゼロショット学習が挙げられるが、ゼロショット学習は事前知識に基づく損失

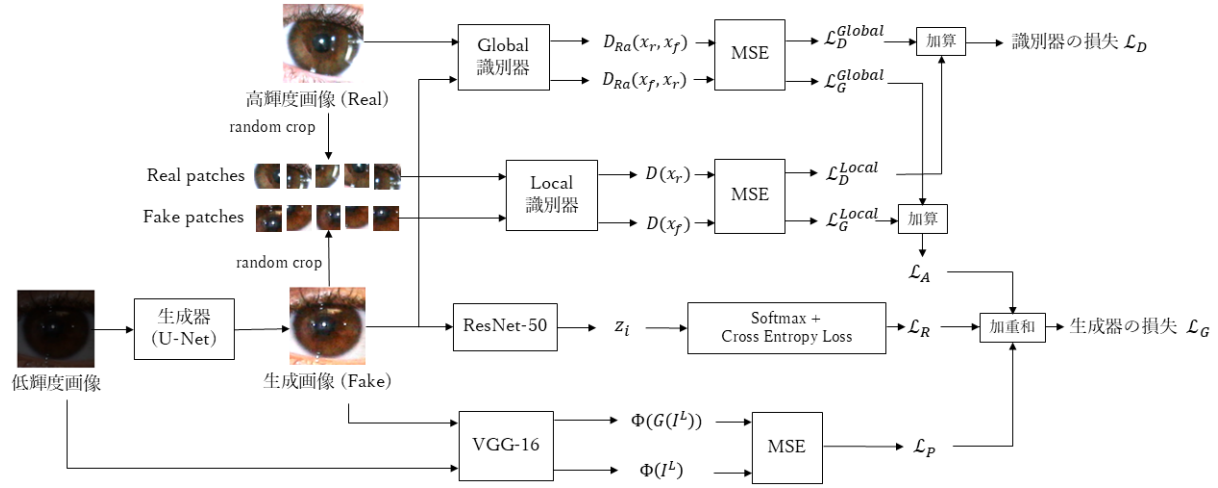


図 1 提案手法における学習方法の概要図

Fig. 1 Outline of learning process in proposed method.

関数に依存している．したがって本稿では，一般画像認識の分野で提案された教師なし学習の輝度補正モデルである EnlightenGAN[8] をベースとした生成器と識別器からなる，可視光虹彩画像のための輝度補正モデルを設計した．

生成器は U-Net[27] を基本構造とし，入力された低輝度画像から高輝度に補正された画像を生成する．また，画像中の暗い領域を優先的に明るくするために Attention 機構を導入している．これは，入力画像の照明成分の明暗を反転したものを自己正則化した Attention map としてすべての中間層と最後の出力に掛け合わせることで，局所照明を考慮した効果的な輝度補正を可能とするものである．

識別器は，入力された画像が学習用の高輝度画像データセットから選択された画像 (Real) であるか，生成器によって生成された画像 (Fake) であるかの識別結果を返す．識別器は 3.2 節で説明する敵対的損失の計算に用いられ，Real として与えられた画像群に近い輝度分布の画像を生成するように生成器に促す．提案手法では，画像全体を入力とする Global 識別器に加えて，画像から切り出した局所パッチを入力する Local 識別器を使用する．Local 識別器を追加することにより，全体的な輝度補正に加えて局所領域における輝度の不足や過剰を回避する効果があることが，EnlightenGAN の原論文において示されている [8]．また Global 識別器では，入力画像が Real である確率を出力する代わりに，Real が入力された場合は Fake，Fake が入力された場合は Real のデータの平均推定値と比べて現実的である確率を出力する Relativistic Discriminator[28] の構造を使用する．

### 3.2 虹彩認証を考慮した損失関数

EnlightenGAN は一般画像認識の輝度補正タスクにおいて視覚的品質を向上させることを目的として提案された手法であり，本研究で対象としている認証タスクを考慮した

ものではないため，認証精度の向上を目指すためには虹彩認証を意識した改良が必要であると考えられる．したがって提案手法では，EnlightenGAN で使用された敵対的損失と知覚損失に加えて，事前学習済みの特徴抽出器を用いた認証損失を導入することにより，個人性を保持し認証に適した虹彩画像を生成するよう生成器の学習を促進する．生成器の学習では 3 つの損失項の加重和を使用する．識別器の学習では敵対的損失を使用する．

敵対的損失は，識別器の出力と正解ラベル (Real=1, Fake=0) の二乗誤差として定義される．敵対的損失を最小化することで，生成器は Real と見分けが付きにくい高輝度画像を生成するようになり，識別器はより正しく Real と Fake を見分けるようになる．生成器の敵対的損失  $\mathcal{L}_G^{Global}$ ， $\mathcal{L}_G^{Local}$  を式 (1) および式 (2)，識別器の敵対的損失  $\mathcal{L}_D^{Global}$ ， $\mathcal{L}_D^{Local}$  を式 (3) および式 (4) に示す． $D_{Ra}(x, y)$  は Global 識別器の出力であり， $x$  が  $y$  よりも現実的である確率を返す． $x_f \sim \mathbb{P}_{fake}$  は Fake の分布  $\mathbb{P}_{fake}$  からランダムにサンプリングしたデータを表しており， $\mathbb{E}_{x_f \sim \mathbb{P}_{fake}}$  は 1 バッチ分の  $x_f$  による計算結果の平均を意味する． $D(x)$  は Local 識別器の出力であり， $x$  が Real である確率を返す．

$$\mathcal{L}_G^{Global} = \frac{1}{2} \mathbb{E}_{x_f \sim \mathbb{P}_{fake}} [(D_{Ra}(x_f, x_r) - 1)^2] + \frac{1}{2} \mathbb{E}_{x_r \sim \mathbb{P}_{real}} [(D_{Ra}(x_r, x_f) - 0)^2] \quad (1)$$

$$\mathcal{L}_G^{Local} = \mathbb{E}_{x_f \sim \mathbb{P}_{fake-patches}} [(D(x_f) - 1)^2] \quad (2)$$

$$\mathcal{L}_D^{Global} = \frac{1}{2} \mathbb{E}_{x_r \sim \mathbb{P}_{real}} [(D_{Ra}(x_r, x_f) - 1)^2] + \frac{1}{2} \mathbb{E}_{x_f \sim \mathbb{P}_{fake}} [(D_{Ra}(x_f, x_r) - 0)^2] \quad (3)$$

$$\mathcal{L}_D^{Local} = \frac{1}{2} \mathbb{E}_{x_r \sim \mathbb{P}_{real-patches}} [(D(x_r) - 1)^2] + \frac{1}{2} \mathbb{E}_{x_f \sim \mathbb{P}_{fake-patches}} [(D(x_f) - 0)^2] \quad (4)$$

知覚損失は、入力の高輝度画像と生成された画像を事前学習済みの VGG-16[29] へ入力して得られた 2 つの特徴マップの平均二乗誤差として定義される。提案手法は生成画像に対する教師画像が存在しないため、低輝度画像と生成画像との間で損失を維持する自己機能を設定するために、知覚損失によって変換前後の画像特徴を保存する。知覚損失  $\mathcal{L}_P$  は式 (5) で与えられる。 $I^L$  は低輝度画像、 $G(I^L)$  は生成器による生成画像、 $\phi_{i,j}$  は VGG-16 の  $i$  番目の Max pooling 層の後の  $j$  番目の畳み込み層の出力を表す。 $W_{i,j}, H_{i,j}$  は、出力マップ  $\phi_{i,j}$  の幅と高さを表す。

$$\mathcal{L}_P = \frac{1}{W_{i,j}H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} (\phi_{i,j}(I^L) - \phi_{i,j}(G(I^L)))^2 \quad (5)$$

認証損失は、事前に可視光虹彩画像で学習した後に重みを固定した ResNet-50[30] を特徴抽出器として、生成器で生成した高輝度画像を入力として計算される Softmax + Cross Entropy Loss として定義する。認証損失  $\mathcal{L}_R$  は以下の式 (6) で与えられる。 $B$  はバッチサイズ、 $C$  はクラス数、 $z_i$  は特徴ベクトル、 $y_i$  は正解クラス、 $A_c$  はクラス  $c$  に対応する重みを表す。

$$\mathcal{L}_R = -\frac{1}{B} \sum_{i=1}^B \log \left( \frac{e^{A_{y_i}^T z_i}}{\sum_{c=1}^C e^{A_c^T z_i}} \right) \quad (6)$$

上記の 3 種類の損失項の加重和として、生成器の損失  $\mathcal{L}_G$  を式 (7) で計算する。 $w_A, w_P, w_R$  は、それぞれの損失項に掛けられる重みである。

$$\mathcal{L}_G = w_A * (\mathcal{L}_G^{Global} + \mathcal{L}_G^{Local}) + w_P * \mathcal{L}_P + w_R * \mathcal{L}_R \quad (7)$$

## 4. 実験の方法

認証損失を使用した場合と使用しなかった場合の 2通りの方法で学習した生成器をそれぞれ輝度補正に用いた際の認証精度を比較し、認証損失を学習に使用することによる効果を示す。また、提案手法と先行研究の手法をそれぞれ輝度補正に用いた際の認証精度を比較し、提案手法が既存手法よりも認証精度を改善できることを示す。実験の学習や評価には PyTorch[31] を使用した。

### 4.1 データセット

本実験では、可視光虹彩認証の研究で広く利用されている UBIRIS.v2[11] データセットを学習及び評価に使用した。このデータセットは、可視光カメラで撮影された 261 人分の虹彩画像 11101 枚で構成されている。被験者はカメラから 4m~8m の距離を 1m ずつ移動しながら、距離ごとに右目と左目を 3 枚ずつ撮影している。また、一部の被験者は 1 週間の間隔を空けて同様の方法でもう 1 度撮影を行っている。UBIRIS.v2 は非理想的な撮影条件を再現する

ことを目的としているため、撮影時の照明の強度や視線の方向、眼鏡の有無、人種などにばらつきが含まれている。

本実験では、データセットのクラス数を増やすために左右の虹彩画像を別のクラスとして扱った。虹彩の大部分が隠れており実験に使用できないと判断した 145 枚を除外し、残った 514 クラス 10956 枚の虹彩画像について、328 クラスを訓練データセット、83 クラスを検証データセット、103 クラスを評価データセットとした。分割後の複数のデータセットに同じクラスは含まれない。

本研究は低輝度の虹彩画像に対する輝度補正の効果を検証することを目的としているため、低輝度の虹彩画像を生成器の入力として与える必要がある。そこで本実験では、4.2 節で説明する前処理を適用した後に、先行研究 [2] に倣い全ての画像の平均輝度が 50 以下になるように全画素に 0.35 以上 0.45 未満の値を乗算して、低輝度の虹彩データセットを生成した。平均輝度が 50 以下の画像はそのまま使用した。また、同様にして全ての画像の平均輝度が 110 以上 140 未満となるような値を全画素に乗算して高輝度の虹彩データセットも生成した。以下、低輝度化したデータセットを Darken、高輝度化したデータセットを Lighten と表記する。ここで、画像の平均輝度  $l$  は各画素の RGB 値 ( $r, g, b$ ) を用いて式 (8) で計算される。

$$l = average(0.299r + 0.587g + 0.114b) \quad (8)$$

### 4.2 前処理

UBIRIS.v2 には異なる距離から撮影された画像が含まれるため、入力する虹彩直径にばらつきがある。この影響を軽減するために、以下の手順で前処理を行った。

- (1) IrisParseNet[32] を用いて虹彩の中心座標と虹彩直径を取得した。
- (2) Bicubic 補間により、虹彩直径が 192 画素になるような画像の大きさを正規化した。
- (3) 虹彩の中心座標を中心に  $224 \times 224$  画素の大きさで画像を切り抜いた。

手順 (1) の虹彩推定で使用した IrisParseNet は、Wang ら [32] が提案した虹彩セグメンテーション手法である。本実験では、UBIRIS.v2 で学習済みのモデルを使用して全画像の虹彩推定を行い、その後に手作業で微調整を行った。

### 4.3 ネットワークの学習方法

認証損失の計算および認証精度の評価に用いる特徴抽出器は、可視光虹彩認証の先行研究で多く採用されている ResNet-50[30] を使用した。特徴抽出器の訓練データセットには Lighten を使用した。特徴ベクトルの次元数は 256、バッチサイズは 16、学習の総イテレーション数は 70000 とした。学習率は初期値を 0.01 とし、60000 イテレーションの時点で 0.1 倍した。オプティマイザはモーメンタム SGD



とし、モーメント係数を 0.9、重み減衰の係数を 0.0005 とした。損失関数は、生成器の認証損失と同一の Softmax + Cross Entropy Loss を使用した。また、訓練データセットにはデータ拡張として Random Rotation, Random Affine, Color Jitter を適用した。検証データセットでの EER が最も低くなった時点のモデルを選択し、すべての学習可能パラメータを固定して生成器の訓練および評価に使用した。

生成器および識別器の学習では、Darken を生成器の入力、Lighten を識別器に入力する Real 画像として使用した。バッチサイズは 32、学習の総エポック数は 200 とした。学習率は初期値を 0.0001 とし、100 エポック目以降は線形に減衰させた。オプティマイザは Adam とし、一次、二次モーメント係数をそれぞれ 0.5、0.999 とした。生成器の学習可能パラメータは、EnlightenGAN の著者らが公開している一般画像で学習済みのモデル [33] を初期値とした。識別器の学習可能パラメータは正規分布に基づく乱数で初期化した。知覚損失の計算に使用する VGG-16 は ImageNet で事前学習済みのモデルを使用し、出力として使用する層は式 (5) の  $i = 5$ ,  $j = 1$  にあたる層とした。式 (7) の生成器の損失関数における各損失項の重みは、検証データセットによる事前実験の結果に基づいて、 $w_A = 1.0$ ,  $w_P = 1.0$ ,  $w_R = 1000.0$  とした。

#### 4.4 評価方法

認証性能の評価指標には Equal Error Rate (EER) を使用した。輝度補正を適用して得られた高輝度画像を特徴抽出器へ入力し、得られた特徴量のマッチング結果から求めたコサイン類似度を用いて EER を算出した。評価に使用する特徴抽出器は、生成器の学習で使用した特徴抽出器と同一のものとした。また、実験結果の信頼性を高めるために、データセットの分割時に選択されるクラスの内訳を乱数の seed を変えることにより変化させ、5 回分の EER の計算結果の平均値を計算した。EER の比較を行う際は、すべての比較対象で共通の特徴抽出器を使用してコサイン類似度の算出を行った。

認証損失の効果を検証する実験では、提案手法で学習した生成器と、認証損失を使用せずに学習を行った生成器の 2 つを比較した。Darken の低輝度虹彩画像に対して各生成器による輝度補正を適用し、それぞれの生成画像を認証に使用した際の EER を比較した。

先行研究との比較実験では、虹彩認証の研究でも広く使用されている CLAHE[12]、ガンマ変換 (Gamma) に加えて、一般画像認識の分野で高い性能を示すとされている LIME[17]、虹彩画像で学習しておらず一般画像でのみ学習済みの EnlightenGAN[8], [33] を比較対象として選択した。それぞれの手法におけるハイパーパラメータは、検証データセットによる事前実験に基づき最も EER が良かった値を採用した。Darken の低輝度虹彩画像に対して各手法に

表 1 学習方法ごとの EER の平均値とコントラスト値

Table 1 Comparison average of EER by learning method.

学習方法	EER [%]	コントラスト値
without $\mathcal{L}_R$	4.43	64.31
with $\mathcal{L}_R$	4.30	67.20




図 2 学習方法ごとの生成画像の平均輝度の分布 (seed=0)

Fig. 2 Brightness distribution of outputs by learning method.

よる輝度補正を適用し、それぞれの生成画像を認証に使用した際の EER を比較した。また、虹彩認証において識別性が高い画像は、虹彩模様の濃淡がはっきりとしたコントラストが強いものであると考えられる。そこで、各生成画像の輝度の標準偏差を計算してコントラスト値とし、手法ごとの比較を行った。

## 5. 実験の結果と考察

### 5.1 認証損失の効果について

表 1 は、学習時の認証損失の有無ごとの EER の平均値をまとめた表である。without  $\mathcal{L}_R$  が認証損失を使用しなかった場合、with  $\mathcal{L}_R$  が認証損失を使用した場合の結果である。図 2 は、学習時の認証損失の有無ごとの生成画像の平均輝度の分布を表したヒストグラムである。Darken, Lighten はそれぞれの評価データセットの画像の平均輝度分布、それ以外は各生成器による補正を Darken の低輝度画像に適用して得られた画像の平均輝度分布を表す。

表 1 より、認証損失を使用した方が EER が低く、認証性能が向上していることが確認できる。また図 2 より、認証損失を使用した方が Lighten の分布範囲に近い輝度分布となっており、目標とする輝度分布へ近づける学習がより進んでいることがわかる。

### 5.2 提案手法と先行研究の比較

表 2 は、輝度補正手法ごとの EER の平均値とコントラスト値をまとめた表である。Baseline は、輝度補正の処理を行わずに 4.2 節の前処理だけを施した Darken の低輝度画像をそのまま特徴抽出器に入力した際の結果である。Proposed は提案手法を適用した結果である。図 3 は、輝

表 2 手法ごとの EER の平均値とコントラスト値

Table 2 Comparison average of EER and contrast by method.

手法	EER [%]	コントラスト値
Baseline	33.12	18.36
CLAHE	6.62	51.13
Gamma	8.59	25.81
LIME	7.38	54.01
EnlightenGAN	9.57	46.30
Proposed	<b>4.30</b>	<b>67.20</b>




図 3 手法ごとの生成画像の平均輝度の分布 (seed=0)

Fig. 3 Brightness distribution of outputs by method.

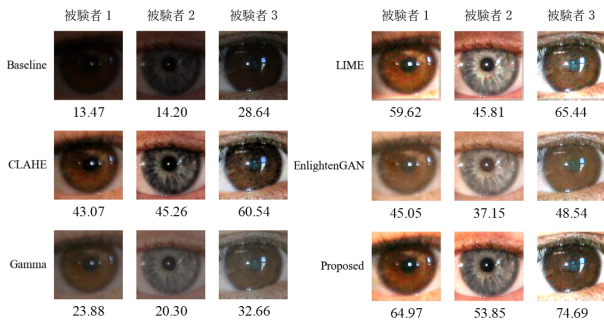


図 4 手法ごとの生成画像の例

Fig. 4 Examples of output images by method.

度補正手法ごとの生成画像の平均輝度の分布を表したヒストグラムである。横軸が画像の平均輝度、縦軸が画像の枚数を表す。Lighten は特徴抽出器の訓練画像および識別器の Real 画像として使用した高輝度画像、それ以外は各手法を Darken の低輝度画像に適用して得られた画像の平均輝度分布を表す。図 4 は、異なる被験者の 3 枚の虹彩画像に各手法を適用して輝度補正を行った画像の例である。虹彩画像の下に数字はその画像のコントラスト値を示す。

表 2 より、Baseline と比較していずれの精度も EER が改善されていることから、低輝度の可視光虹彩認証において輝度補正処理が認証精度の改善に有効であることが確認できた。既存の輝度補正手法と精度を比較した結果、提案手法が最も良い精度で認証できることが示された。さらに、図 3 より Proposed の生成画像の輝度分布が Lighten の範囲にほとんど収まっていることから、識別器や認証損

失による輝度分布を Lighten のものに近付ける効果が表れていることが確認できる。

また、表 2 と図 3 によると、生成画像の輝度が低い CLAHE の EER が高輝度化効果の強い EnlightenGAN の EER を下回っており、必ずしも輝度が高いほど認証精度が高くなっているわけではないことが分かる。表 2 と図 4 より各手法の生成画像のコントラスト値を比較すると、CLAHE の生成画像は輝度は低いが高コントラスト値が高く、虹彩模様の濃淡が強調されている一方で、EnlightenGAN の生成画像はコントラスト値が CLAHE より低く、全体的にぼやけたような画像になっている。これらに対して、EER が最も良い Proposed の生成画像はコントラスト値も比較対象の中で最も高くなっており、提案手法によってコントラストも含めた虹彩模様の認識性を改善されたことで認証性能が改善されたと考えられる。

### 5.3 研究倫理

本稿における研究倫理について研究者同士で議論し、実験手順の正当性について検討を行った。本稿の実験で使用した UBIRIS.v2 データセット [11] は、Proenca らによって収集、公開された虹彩画像データセットである。使用の際には管理者と連絡を取り、利用許諾を受けてダウンロードした。また、ダウンロードしたデータセットは適切に管理を行い、利用規約を遵守した上で実験に使用した。したがって、本稿の実験によってプライバシーをはじめとする研究倫理に抵触することはないと考える。

## 6. 結論と今後の課題

本稿では、可視光虹彩認証において低輝度の入力画像を適切な輝度に補正する前処理を実現するために、虹彩認証の認証損失を組み込んだ教師なし学習可能な深層学習モデルを提案した。実験の結果、低輝度の可視光虹彩認証における輝度補正の前処理として提案手法を適用することで、既存の非深層学習の補正手法を適用した中で最も良かった結果と比較して EER が 6.62% から 4.30% に改善されることを示した。今後の課題として、より効果的な識別器の設計やデータセットの構成方法についての研究が挙げられる。

### 参考文献

- [1] 一般社団法人日本自動認識システム協会：よくわかる生体認証，オーム社 (2019)．
- [2] Wang, Z., Deng, W., Ge, J.: FIE-GAN: Illumination Enhancement Network for Face Recognition, *Pattern Recognition and Computer Vision*, Vol. 13021, pp. 214–225 (2021)．
- [3] Fan, Y., Wang, Y., Liang, D., Chen, Y., Xie, H., Wang, F. L., Li, J., Wei, M.: Low-FaceNet: Face Recognition-Driven Low-Light Image Enhancement, *IEEE Transactions on Instrumentation and Measurement*, Vol. 73, pp. 1–13 (2024)．

- [4] Tao, L., Zhu, C., Xiang, G., Li, Y., Jia, H., Xie, X.: LL-CNN: a Convolutional Neural Network for Low-Light Image Enhancement, *IEEE Visual Communications and Image Processing*, pp. 1-4 (2017).
- [5] Shen, L., Yue, Z., Feng, F., Chen, Q., Liu, S., Ma, J.: MSR-Net: Low-Light Image Enhancement using Deep Convolutional Network, *arXiv:1711.02488*, pp. 1-9 (2017).
- [6] Wei, C., Wang, W., Yang, W., Liu, J.: Deep Retinex Decomposition for Low-Light Enhancement, *arXiv:1808.04560*, pp. 1-12 (2018).
- [7] Cai, J., Gu, S., Zhang, L.: Learning a Deep Single Image Contrast Enhancer from Multi-Exposure Images, *IEEE Transactions on Image Processing*, Vol. 27, No. 4, pp. 2049-2062 (2018).
- [8] Jiang, Y., Gong, X., Liu, D., Cheng, Y., Fang, C., Shen, X.: EnlightenGAN: Deep Light Enhancement without Paired Supervision, *IEEE Transactions on Image Processing*, Vol. 30, pp. 2340-2349 (2021).
- [9] Zhu, A., Zhang, L., Shen, Y., Ma, Y., Zhao, S., Zhou, Y.: Zero-Shot Restoration of Underexposed Images via Robust Retinex Decomposition, *IEEE International Conference on Multimedia and Expo*, pp. 1-6 (2020).
- [10] Guo, C., Li, C., Guo, J., Loy, C. C., Hou, J., Kwong, S., Cong, R.: Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement, *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 1780-1789 (2020).
- [11] Proenca, H., Filipe, S., Santos, R., Oliveira, J., Alexandre, L. A.: The UBIRIS.v2: A Database of Visible Wavelength Iris Images Captured On-the-Move and At-a-Distance, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 32, No. 8, pp. 1529-1535 (2010).
- [12] Pizer, S. M., Amburn, E. P., Austin, J. D., Cromartie, R., Geselowitz, A., Greer, T., Romeny, B. H., Zimmerman, J. B., Zuiderveld, K.: Adaptive Histogram Equalization and its Variations, *Graphics Gems IV*, Academic Press (1994).
- [13] Land, E. H.: Lightness and Retinex Theory, *Journal of the Optical Society of America*, Vol. 61, No. 1, pp. 1-11 (1971).
- [14] Jobson, D. J., Rahman, Z., Woodell, G. A.: Properties and Performance of a Center/Surround Retinex, *IEEE Transactions on Image Processing*, Vol. 6, No. 3, pp. 451-462 (1997).
- [15] Jobson, D. J., Rahman, Z., Woodell, G. A.: A Multiscale Retinex for Bridging the Gap between Color Images and the Human Observation of Scenes, *IEEE Transactions on Image Processing*, Vol. 6, No. 7, pp. 965-976 (1997).
- [16] Fu, X., Zeng, D., Huang, Y., Zhang, X. P., Ding, Z.: A Weighted Variational Model for Simultaneous Reflectance and Illumination Estimation, *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2782-2790 (2016).
- [17] Guo, X., Li, Y., Ling, H.: LIME: Low-Light Image Enhancement via Illumination Map Estimation, *IEEE Transactions on Image Processing*, Vol. 26, No. 2, pp. 982-993 (2017).
- [18] Hassan, R., Kasim, S., Jafery, W., Shah, Z.: Image Enhancement Technique at Different Distance for Iris Recognition, *International Journal on Advanced Science Engineering Information Technology*, Vol. 7, No. 4-2, pp.1510-1515 (2017).
- [19] Sajjad, M., Ahn, C. W., Jung, J. W.: Iris Image Enhancement for the Recognition of Non-Ideal Iris Images, *KSI Transactions on Internet and Information Systems*, Vol. 10, No. 4, pp. 1904-1926 (2016).
- [20] Alvarez-Betancourt, Y., Garcia-Silvente, M.: A Keypoints-Based Feature Extraction Method for Iris Recognition under Variable Image Quality Conditions, *Knowledge-Based Systems*, Vol. 92, pp. 169-182 (2016).
- [21] Santos, G., Hoyle, E.: A Fusion Approach to Unconstrained Iris Recognition, *Pattern Recognition Letters*, Vol. 33, No. 8, pp. 984-990 (2012).
- [22] Alwawi, B. K. O. C., Althabhwae, A. F. W.: Towards More Accurate and Efficient Human Iris Recognition Model using Deep Learning Technology, *TELKOMNIKA Telecommunication Computing Electronics and Control*, Vol. 20, No. 4, pp. 817-824 (2022).
- [23] Kumar, D., Sastry, M., Manikantan, K.: Iris Recognition using Contrast Enhancement and Spectrum-Based Feature Extraction, *International Conference on Emerging Trends in Engineering, Technology and Science*, pp. 1-7 (2016).
- [24] Das, R., Derakhshani, R.: Using Transfer Learning and BPDFHE to Improve Ocular Image Recognition Accuracy, *IEEE International Symposium on Technologies for Homeland Security*, pp. 1-6 (2019).
- [25] Sheet, D., Garud, H., Suveer, A., Mahadevappa, M., Chatterjee, J.: Brightness Preserving Dynamic Fuzzy Histogram Equalization, *IEEE Transactions on Consumer Electronics*, Vol. 56, No. 4, pp. 2475-2480 (2010).
- [26] Raffei, A. F. M., Asmuni, H., Hassan, R., Othman, R. M.: A Low Lighting or Contrast Ratio Visible Iris Recognition using iso-Contrast Limited Adaptive Histogram Equalization, *Knowledge-Based Systems*, Vol. 74, pp. 40-48 (2015).
- [27] Ronneberger, O., Fischer, P., Brox, T.: U-Net: Convolutional Networks for Biomedical Image Segmentation, *Medical Image Computing and Computer-Assisted Intervention*, pp. 234-241 (2015).
- [28] Jolicoeur-Martineau, A.: The Relativistic Discriminator: a Key Element Missing from Standard GAN, *arXiv:1807.00734*, pp. 1-25 (2018).
- [29] Simonyan, K., Zisserman, A.: Very Deep Convolutional Networks for Large-Scale Image Recognition, *arXiv:1409.1556*, pp. 1-14 (2015).
- [30] He, K., Zhang, X., Ren, S., Sun, J.: Deep Residual Learning for Image Recognition, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770-778 (2016).
- [31] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., Chintala, S.: PyTorch: An Imperative Style, High-Performance Deep Learning Library, *Advances in Neural Information Processing Systems*, Vol. 32, pp. 8024-8035 (2019).
- [32] Wang, C., Muhammad, J., Wang, Y., He, Z., Sun, Z.: Towards Complete and Accurate Iris Segmentation using Deep Multi-Task Attention Network for Non-Cooperative Iris Recognition, *IEEE Transactions on Information Forensics and Security*, Vol. 15, pp. 2944-2959 (2020).
- [33] Y. Jiang: EnlightenGAN: Deep Light Enhancement without Paired Supervision (online), 入手先 (<https://github.com/VITA-Group/EnlightenGAN>) (閲覧 2025-08-12)